

Prosjekt Rapport

INF161 – Ella Mathilde Solberg



UNIVERSITETET I BERGEN

Innholdsfortegnelse

Innledning.....	3
Datatilberedning	3
<i>Innhenting av data</i>	<i>3</i>
<i>Sammenslåing av datasett</i>	<i>4</i>
<i>Videre datavasking</i>	<i>4</i>
<i>Håndtering av NaN-verdier</i>	<i>5</i>
<i>Deler opp i treningsdata, testdata og valideringsdata</i>	<i>5</i>
<i>OneHotEncoder</i>	<i>5</i>
Utforskende dataanalyse og visualisering	6
<i>Describe</i>	<i>6</i>
<i>Visualiseringer</i>	<i>6</i>
Datamodellering.....	19
<i>Fjerning av uteliggere.....</i>	<i>19</i>
<i>Feature Engineering</i>	<i>20</i>
<i>Oppretting av gjennomsnittsvariabler for overlevelsesestimat.....</i>	<i>20</i>
<i>Oppretting av helsetilstand variabel</i>	<i>21</i>
<i>Baseline</i>	<i>23</i>
<i>Valg av modell</i>	<i>23</i>
<i>Feature importance.....</i>	<i>24</i>
<i>Generaliseringsevne</i>	<i>24</i>
Predikasjon	26
Konklusjon	26
Referanseliste	27

Innledning

I dette prosjektet skal jeg bygge en maskinlæringsmodell for å predikere den forventede lengden på sykehusopphold per pasient. Modellen skal bruke pasientopplysninger-, inkludert fysiologiske-, demografiske- og sykdomsalvorlighetsgraddata på tvers av ni sykdomskategorier, for å predikere oppholds lengde. Dataen modellen skal hente inn er fra fire ulike datasett fra fem medisinske sentre i USA. Dataen er fra perioden 1989-1991 og 1992-1994. Hver pasient i datasettet er innlagte pasienter som oppfylte inklusjons- og eksklusjonskriteriene for ni sykdomskategorier: akutt respirasjonssvikt, kronisk obstruktiv lungesykdom, hjertesvikt, leversykdom, koma, tykktarmskreft, lungekreft, multiple organsvikt med malignitet og multiple organsvikt med sepsis. Målet er å nøyaktig anslå lengden på sykehusopphold for nye pasienter basert på disse variablene.

Datatilberedning

Denne delen skal ta inn rådata og lage en dataframe som kan brukes i maskinlæringsmodellen. Den inneholder databeskrivelse, utforskende dataanalyse, visualisering og andre datatilberedning.

Innhenting av data

Data blir lastet inn fra fire ulike filer: «demographic.csv», «hospital.csv», «physiological.txt» og «severity.json». I tillegg til dette renses dataen ved å fjerne negative oppholdsverdier og i tillegg til noen andre operasjoner på datasettet.

- Inntektsmapping: Konverterer kategoriske inntektsnivåer til numeriske verdier for enklere behandling. Dette kan gjøres med mapping fordi inntektsnivåene har en naturlig rangering fra lav til høy. Hvis nivåene ikke hadde en rangering, ville det vært mer hensiktsmessig å bruke OneHotEncoder i stedet.
- Fjerning av negative verdier: For oppholdslengde og alder fjernes negative verdier. Grunnen er at dette er urealistiske verdier som kan påvirker modellen negativt.

- Explosion av df_severity: Omstrukturer severity slik at hver pasient har separate rader med tilhørende sykdomskategorier.

Sammenslåing av datasett

Datasettene slås sammen ved hjelp av pasient_id, slik at alle relevante variabler er samlet i ett datasett for videre analyse og modellering.

Videre datavasking

Datasettet blir videre vasket for å redusere støy og sikre at unøyaktige eller irrelevante verdier ikke påvirker modellens ytelse. Dette gir bedre datakvalitet og et mer pålitelig datagrunnlag for analysen.

- Fjerning av duplikater: Fjerner duplikater slik at hver pasient kun er representert en gang i datasettet, dette er med på å forhindre skjevheter.
- Fjerner rader med negativ alder: Deretter fjerner jeg urealistiske verdier, som negativ alder. Slike type verdier kan komme av feil i datainnsamling o.l. og kan påvirke modellens ytelse.
- Fjerner sykdomskategorier: Fjerner sykdomskategorier siden dette er informasjon som allerede finnes i variablene for sykdomsunderkategori. Noe som gjør at sykdomskategori variabelen blir overflødig. Ved å fjerne denne reduseres mengden støy i datasettet og modellen kan fokusere bedre på de variablene som gir spesifikk og relevant informasjon.
- Fjerner av adl_pasient og adl_stedfortreder: Fjerner adl_pasient fordi den blir målt på dag 7. Fjerner adl_stedfortrtreder fordi den har veldig høyt nivå av NaN-verdier.
- Fjerner DNR status: DNR-status fjernes, da den ikke har direkte innvirkning på oppholdslengden.
- Fjerner verdier målt på dag 7: Fjerner bilirubin variabelen siden den er målt på dag 7. Siden vi skal predikere fra dag 1, har verdier målt på dag 7 ingen innvirkning.

- Fjerner dødsfall, sykehusdød og pasient_id: Fjerner dødsfall og sykehusdød fordi de viser kjente utfall som kan påvirke prediksjonene. Fjerner pasient_id da det kun er en indeksering.

Håndtering av NaN-verdier

Fyller inn manglende verdier med hjelp av anbefalte verdier på denne måten blir det ett mer komplett datasett.

```
df['serumalbumin'].fillna(3.5, inplace=True)
df['lungefunksjon'].fillna(333.3, inplace=True)
df['bilirubin'].fillna(1.01, inplace=True)
df['kreatinin'].fillna(1.01, inplace=True)
df['blodurea_nitrogen'].fillna(6.51, inplace=True)
df['hvite_blodlegemer'].fillna(9, inplace=True)
df['urinmengde'].fillna(2502, inplace=True)
```

Figur 1: Innsetting av anbefalte verdier

Deler opp i treningsdata, testdata og valideringsdata

Datasettet deles opp i trenings-, validerings- og testsett. Treningssett brukes til å lære modellen, valideringssettet brukes til å finjustere hyperparametere, og testsettet gir en siste, uavhengig evaluering av modellens ytelse.

OneHotEncoder

Bruker OneHotEncoder til å konvertere kategoriske variabler til numeriske variabler slik at maskinlæringsmodellen kan bruke dem. Jeg har valgt å bruke OneHotEncoder i stede for `pd.get_dummies()` fordi OneHotEncoder håndterer ukjente kategorier bedre. I tillegg gir OneHotEncoder mulighet til å få et resultat som er mer pandas-vennlig, noe som gjør det enkelt å legge de nye kolonnene tilbake i datasettet. Dette gjør OneHotEncoder til et bra valg for denne oppgaven.

```

ohe = OneHotEncoder(handle_unknown='ignore', sparse_output=False).set_output(transform='pandas')
ohe_transformed_severity = ohe.fit_transform(df_severity[['sykdomskategori_id',
                                                         'sykdomskategori', 'sykdom_underkategori',
                                                         'kreft',
                                                         'dnr_status']], )
df_severity = pd.concat([df_severity, ohe_transformed_severity], axis=1).drop(columns = ['sykdomskategori_id',
                                                         'sykdomskategori',
                                                         'sykdom_underkategori',
                                                         'kreft',
                                                         'dnr_status'])

ohe_transformed_demographic = ohe.fit_transform(df_demographic[['kjønn', 'etnisitet']])
df_demographic = pd.concat([df_demographic, ohe_transformed_demographic], axis=1).drop(columns = ['kjønn', 'etnisitet'])

```

Figur 2: Kode for OneHotEncoder

Utforskende dataanalyse og visualisering


For å få en forståelse av datasettet og identifisere mønstre, uteliggere og sammenhenger, ble det utført en utforskende dataanalyse. Ved å kombinere beskrivende statistikk og visualiseringer, kan man avdekke viktige strukturer i dataene. Dataanalysen er viktig for videre forbedring av dataen. I denne rapporten har jeg kun inkludert de visualiseringene som er viktig for videre dataforberedelser.

Describe

For å få en bedre forståelse av datasettet startet jeg med en utforskende analyse ved hjelp av describe-metoden. Denne metoden gir en statistisk oversikt over de numeriske variablene i datasettet, inkludert informasjon om gjennomsnitt, standardavvik, minimums- og maksimumsverdier og kvartiler. Gjennom describe-metoden kan man raskt identifisere verdier som var urealistiske, som for eksempel NaN og uteliggere, noe som senere la grunnlaget for ytterligere datarensing og uteliggerhåndtering. Den gir også informasjon om fordelingen av oppholdslengder. Den høye maksverdien i forhold til gjennomsnittet kan indikere tilstedeværelsen av uteliggere, noe som kan påvirke analyseresultatene. Altså at vi har noen pasienter med veldig høy oppholdslengde.

Visualiseringer


Forhold mellom antall_komorbiditeter og oppholdslengde



Figur 3: Sammenheng mellom antall komorbiditeter og oppholdslengde

Dette scatterplottet viser sammenhengen mellom antall komorbiditeter og oppholdslengde på sykehuset. Man kan se at pasienter med færre komorbiditeter generelt har stor variasjon i oppholdslengde, inkludert noen med veldig lange opphold. For pasienter med flere komorbiditeter ser vi en tendens til kortere opphold. Dette kan indikere at pasienter med mange komorbiditeter enten får raskere behandling og utskrivelse, eller at de har et annet sykdomsbilde som påvirker lengden på sykehusoppholdet. Scatterplotet gir en indikasjon på at antall komorbiditeter kan være en faktor i modelleringen av oppholdslengde, men at sammenhengen ikke er lineær.

Forhold mellom hvite_blodlegemer og oppholdslengde




Figur 4: Forhold mellom hvite blodlegemer og oppholdslengde

Dette scatterplottet viser forholdet mellom antall hvite blodlegemer og oppholdslengde. Hvite blodlegemer spiller en viktig rolle i immunsystemet og kan ofte være forhøyet ved infeksjoner eller betennelsestilstander.

Observasjoner:

- Flesteparten av pasientene har en lavere konsentrasjon av hvite blodlegemer, og deres oppholdslengde varierer i stor grad. Dette kan tyde på at hvite blodlegemer alene ikke nødvendigvis bestemmer lengden på oppholdet, selv om forhøyede nivåer ofte assosieres med infeksjoner.
- Høyere antall hvite blodlegemer er relativt sjeldne og ser ikke ut til å ha en sterk sammenheng med lange opphold, da oppholdslengden varierer uavhengig av nivået.
- Noen av de lengste oppholdene er assosiert med moderate nivåer av hvite blodlegemer, noe som kan tyde på at andre faktorer også påvirker oppholdslengden.




Figur 5: Forhold mellom overlevelsesestimater 2 mnd og oppholdslengde

Dette scatterplottet viser forholdet mellom overlevelsesestimater etter 2 måneder og oppholdslengde. Estimater for overlevelse etter 2 måneder representerer sannsynligheten for at pasienten overlever i to måneder etter innleggelse, hvor 1 indikerer høy sannsynlighet for overlevelse, mens 0 representerer lav sannsynlighet.

Observasjoner:

- Det ser ut til å være en svak trend der pasienter med lavere overlevelsesestimater har en bredere variasjon i oppholdslengde, inkludert flere lange opphold. Dette kan skyldes at disse pasientene har mer alvorlige tilstander, som krever lengre behandling eller intensiv omsorg.
- Pasienter med høyere overlevelsesestimater har generelt kortere oppholdslengder, noe som kan indikere at disse pasientene har bedre helse eller færre komplikasjoner, og dermed raskere blir utskrevet.
- Den store konsentrasjonen av punkter rundt lave oppholdslengder på tvers av alle overlevelsesestimater antyder at de fleste pasientene opplever kortere sykehusopphold.



Figur 6: Forhold mellom overlevelsesestimat 6 mnd og oppholdslengde


Dette scatterplottet viser forholdet mellom overlevelsesestimatet etter 6 måneder og oppholdslengde. Overlevelsesestimatet etter 6 måneder gir en vurdering av pasientens sjanse for å overleve i seks måneder etter innleggelse, der verdier nær 1 indikerer høy sannsynlighet for overlevelse, mens verdier nær 0 indikerer lav sannsynlighet.

Observasjoner:

- Det er en stor ansamling av punkter med kort oppholdslengde på tvers av alle overlevelsesestimater, noe som antyder at de fleste pasientene uansett har et kortere opphold.
- Pasienter med lave overlevelsesestimater har mer variert oppholdslengde, med noen opphold som strekker seg opp til 200 dager eller mer. Dette kan tyde på at pasienter

med høy risiko for tidlig død ofte har behov for lengre eller mer kompleks behandling.

- For pasienter med høyere overlevelsesestimer ser vi en trend mot kortere oppholdslengder. Dette antyder at pasienter med bedre prognoser generelt har mindre behov for langvarige opphold.




Figur 7: Forhold mellom lege overlevelsesestimat 2 mnd og oppholdslengde

Dette scatterplottet illustrerer forholdet mellom legens overlevelsesestimat for de neste 2 månedene og oppholdslengden på sykehuset. X-aksen viser legens vurdering av sannsynligheten for at pasienten overlever de neste to månedene og y-aksen viser oppholdslengde i dager.

Observasjoner:

- Lave overlevelsesestimer: Pasienter med lavt overlevelsesestimat har en tendens til kortere opphold, med få utstikkere som oppholder seg lengre. Dette kan indikere en høy risiko for tidlig død eller raskere utskrivning.
- Moderat til høyt overlevelsesestimat: Innenfor denne gruppen er det en større variasjon i oppholdslengde, fra svært korte opphold til noen få lange opphold. Dette

antyder at pasienter med høyere overlevelsessannsynlighet har en blanding av korte og lengre opphold, avhengig av behandlingsbehov og medisinsk stabilitet.




Figur8: Forhold mellom lege overlevelsesestimat 6 mnd og oppholdslengde

Dette scatterplottet viser forholdet mellom legens overlevelsesestimat for 6 måneder og oppholdslengde på sykehuset. På x-aksen er legens vurdering av pasientens sjanse til å overleve de neste 6 månedene, mens y-aksen viser oppholdslengden i dager.

Observasjoner:

- Lave overlevelsesestimater: Pasienter med lav sannsynlighet for overlevelse over 6 måneder ser ut til å ha varierte oppholdslengder, men mange har relativt korte opphold. Dette kan skyldes alvorlige helsetilstander som kan føre til rask forverring og kortere opphold.
- Moderat til høyt overlevelsesestimat: Her er det en høy variasjon i oppholdslengder. Mange pasienter med høyere overlevelsesestimater har korte opphold, noe som kan indikere en stabil helseforbedring, mens noen få pasienter har lengre opphold, muligens på grunn av kroniske tilstander som krever langvarig behandling.




Figur 4: Oppholdslengde i forhold til kjønn

Dette boxplottet viser oppholdslengden fordelt på kjønn. Plottet sammenligner fordelingen av oppholdslengde mellom menn og kvinner.

Observasjoner:

- Median oppholdslengde er lik for begge kjønn, noe som indikerer at kjønn i seg selv ikke har en stor direkte innvirkning på hvor lenge pasienter er innlagt.
- Det er flere uteliggere i begge grupper, spesielt blant menn, der noen har betydelig lengre opphold enn flertallet.




Figur 5: Forhold mellom oppholdslengde og fysiologisk score

Dette scatterplottet viser forholdet mellom fysiologisk score og oppholdslengde. Vi ser at majoriteten av pasientene har en fysiologisk score under 50, og det er en konsentrasjon av oppholdslengder mellom 0 og 100 dager.

Noen observasjoner:

- Pasienter med lave fysiologiske scorere viser stor variasjon i oppholdslengde, noe som tyder på at en lav score ikke nødvendigvis er en indikator for kortere opphold.
- Pasienter med høye fysiologiske scorere har generelt kortere oppholdslengde. Dette kan indikere at høye fysiologiske scorere er knyttet til mer alvorlige tilstander, som enten fører til rask utskrivelse på grunn av bedring eller, i noen tilfeller, dødsfall.
- Det er få observasjoner med både høy fysiologisk score og lang oppholdslengde, noe som antyder at slike kombinasjoner er sjeldne og sannsynligvis gjenspeiler et alvorlig sykdomsbilde med kortvarig behandling.




Figur 6: Forhold mellom APACHE fysiologisk score og oppholdslengde

Dette scatterplottet viser sammenhengen mellom APACHE fysiologisk score og oppholdslengde på sykehuset, der hver prikk representerer en pasient. APACHE-score, som måler pasientens fysiologiske tilstand og alvorlighetsgrad ved innleggelse, er plottet på x-aksen, mens oppholdslengden i dager vises på y-aksen.

Observasjoner:

- Lavere APACHE-score: De fleste pasientene ligger innenfor dette score-området og viser et bredt spekter av oppholdslengder, med noen som har korte opphold og andre som har opphold som strekker seg til over 100 dager.
- Moderat APACHE-score: Pasienter med en moderat APACHE-score viser generelt kortere oppholdslengder, noe som kan tyde på at pasienter i denne score-gruppen får intensiv behandling, men kan forbedres relativt raskt.
- Høy APACHE-score: Pasienter med svært høye APACHE-scorer har generelt kortere opphold. Dette kan skyldes at høye scoringsverdier ofte indikerer en alvorlig tilstand som kan føre til raskt dødsfall eller beslutning om begrenset behandling



Figur 7: Forhold mellom koma score og oppholdslengde


Dette scatterplottet viser sammenhengen mellom koma-score og oppholdslengde på sykehuset. Hver prikk representerer en pasient, med koma-score på x-aksen og oppholdslengde på y-aksen.

Observasjoner:

- Lave koma-scorer: Majoriteten av pasientene har lave koma-scorer, og disse pasientene ser ut til å ha en bred variasjon i oppholdslengde, med noen få tilfeller av svært langvarige opphold.
- Middels koma-scorer: Pasienter med middels koma-scorer har også varierte oppholdslengder, men tendensen ser ut til å være kortere opphold enn for de med svært lave koma-scorer.
- Høye koma-scorer: For de høyeste koma-scorene er antallet pasienter lavt, og oppholdslengden er generelt kortere, noe som kan indikere dårligere prognoser eller dødsfall kort tid etter innleggelse.

Dette plottet antyder at pasienter med høy koma-score har kortere opphold, noe som kan skyldes at koma-scoren reflekterer en alvorlig tilstand som kan føre til raskt dødsfall eller

beslutninger om palliativ omsorg. For lave koma-scorer ser vi større variasjon, noe som kan indikere at andre faktorer også påvirker oppholdslengden i disse tilfellene.




Figur 8: Spredning i oppholdslengde per sykdom

Dette boxplottet viser oppholdslengden for pasienter fordelt på ulike sykdomskategorier og spesifikke sykdomsgrupper. Hver kategori representerer en bestemt sykdom og hvert punkt viser oppholdslengden for individuelle pasienter innen den gruppen.

Observasjoner:

- Forskjeller i oppholdslengde: Median oppholdslengde varierer mellom de ulike sykdomsgruppene, noe som indikerer at spesifikke sykdommer har forskjellige påvirkninger på oppholdets varighet.
- Uteliggere: Flere sykdomsgrupper, som diabetes, kreft, og ARF/MOSF med sepsis, viser et stort antall uteliggere med lengre opphold. Dette kan indikere at visse alvorlige tilfeller innen disse gruppene krever lengre behandling.

- Variasjon i spredning: Enkelte sykdomsgrupper, spesielt de med alvorlige tilstander som kreft og ARF/MOSF med sepsis, har en større spredning i oppholdslengde sammenlignet med andre grupper.



Figur 9: Korrelasjonsmatrise for alle variabler i datasettet

Denne korrelasjonsmatrisen viser sammenhengen mellom ulike variabler i datasettet, der korrelasjonskoeffisienten varierer mellom -1 og 1. En verdi nær 1 indikerer en sterk positiv korrelasjon, mens en verdi nær -1 indikerer en sterk negativ korrelasjon. Variabler med høy korrelasjon vises med sterke rød eller blå farger.

Observasjoner:

- Sterk positiv korrelasjon: Enkelte variabler, som overlevelsesestimer på 2 og 6 måneder (fra både medisinske modeller og leger), har høy positiv korrelasjon. Dette indikerer at disse variablene måler liknende aspekter og kan påvirke hverandre.
- Sterk negativ korrelasjon: Det er noen områder med sterk negativ korrelasjon, spesielt mellom fysiologiske scorere. Dette kan tyde på at dårligere fysiologiske scorere er knyttet til lavere overlevelsesestimat.
- Svake korrelasjoner: De fleste variablene viser svak eller ingen korrelasjon med hverandre, noe som kan indikere at variablene bidrar med unik informasjon uten mye overlapp.


Datamodellering

Denne delen av prosjektet tar utgangspunkt i den forberedte Datadramen og bygger en maskinlæringsmodell for å predikere lengden på sykehusopphold. Det ble også utført datarensing, variabelutvelgelse og håndtering av manglende verdier. Fire forskjellige modeller og ulike imputasjonsmetoder ble testet, og modellens ytelse ble evaluert ved hjelp av RMSE. Til slutt ble den beste kombinasjonen av modell og imputasjon valgt basert på lavest RMSE-verdi.

Fjerning av uteliggere

Uteliggere er ekstremerverdier som skiller seg fra resten av dataen. De kan oppstå på forskjellige måter inkludert målefeil, sjeldne hendelser eller ulike egenskaper hos datapunktene. For å redusere påvirkningen av disse verdiene, begrenses uteliggere i datasettet. Dette er med på å forhindre skjevhet i modellen.

- Identifisering av uteliggere: Ved hjelp av boxplot visualisering blir det identifisert uteliggere i urinmengde, kreatinin, hvite blodlegemer og glukose.



Figur 10: Visualisering av uteliggere i urinmengde


- Klipping av verdier: For variabler med ekstreme uteliggere blir dataene klippet til bestemte prosentiler. 25. og 75. prosentil for urinmengde, 95. prosentil for kreatinin og hvite blodlegemer. Dette reduserer påvirkningen av de mest ekstreme verdiene og gir en jevnere fordeling, noe som bidrar til en modell med bedre ytelse og lavere risiko for overfitting til unormale datapunkter.
- Utfører på alle datasett: For å sikre konsistens og redusere risikoen for skjevhet utføres det samme klipping av uteliggere på trenings-, validerings- og testsett.

Feature Engineering

For å forbedre modellens ytelse og gjøre slik at de viktigste egenskapene ved dataene kommer tydelig frem, er det blir gjort feature engineering. Dette innebærer blant annet oppretting av nye variabler.

Oppretting av gjennomsnittsvariabler for overlevelsesestimat

Det ble observert høy korrelasjon mellom overlevelsesestimat på 2 og 6 måneder, både for legens og modellens vurdering. For å gjøre analysen bedre ble det opprettet to nye variabler




Figur 11: Korrelasjonsmatrise over de øvrige variablene


- tidlig_overlevelsesestimat_gjennomsnitt: Gjennomsnittet av legens og modellens 2-måneders overlevelsesestimat og 6-måneders overlevelsesestimat.
- sen_overlevelsesestimat_gjennomsnitt: Gjennomsnittet av legens og modellens 6-måneders overlevelsesestimat.
- Disse variablene gir en sammenfattet vurdering av overlevelsesprognosen, samtidig fremhever det noen av de viktige egenskapene i datasettet.

Oppretting av helsetilstand variabel

Basert på observasjoner av sammenhengen mellom fysiologisk score og koma score, blir det opprettet en ny variabel, helsetilstand som er produkt av disse to scorene. Denne variabelen gir en indikator på den generelle helsetilstanden og sykdommens alvorlighetsgrad, og kan bidra til å fange opp sammenhengen mellom helsetilstand og oppholdslengde.



Figur 12: Sammenhengen mellom oppholdslengde og fysiologisk score



Figur 13: Sammenhengen mellom oppholdslengde og koma score

Baseline

For å ha et utgangspunkt for å vurdere ytelsen til de andre modellene som skal testes, er det opprettet en baseline-modell ved hjelp av en `DummyRegressor`. Baseline-modellen bruker en strategi, der den alltid predikerer gjennomsnittsverdien av oppholdslengden i treningsdataen. Dette gir en predikasjon som verken tar hensyn til noen funksjoner eller variasjon i dataene. Resultatet fra baseline-modellen ga en RMSE på 18.68, som representerer feilen når man predikerer gjennomsnittet. For at en modell skal anses som bedre må den oppnå en lavere RMSE enn denne.

Valg av modell

For å finne den beste kombinasjonen av modell og metode for imputering av NaN-verdier, ble det testet flere ulike strategier.

- **Imputasjonsstrategier:** Det inkluderte både enkle metoder og mer avanserte teknikker for å håndtere manglende verdier. Blant de enklere metodene ble det testet med gjennomsnitt, median, most frequent. Blant de mer avanserte metodene, ble det testet blant annet, som KNN-imputering (med forskjellige verdier for antall naboer: 10, 50, 100 og 150), testet for å se om de kunne forbedre resultatene ved å bruke data fra nabolaget til å erstatte manglende verdier.
- **Modeller:** parallelt ble ulike modeller evaluert, inkluder `RandomForestRegressor`, `Lasso`, `MLPRegressor` og `GradientBoostingRegressor`. Hver modell ble konfigurert med ulike hyperparametre, som antall estimatorer, dybde og læringsrate, for å teste ulike tilpasningsnivåer til dataene. Disse modellene ble deretter trent på treningssettet med de forskjellige imputasjonsstrategiene og evaluert på valideringssettet ved hjelp av RMSE for å vurdere ytelsen til hver kombinasjon.
- **Sammenligning:** For å sammenligne ytelsen, ble RMSE beregnet for hver modell og imputasjonsstrategi. Den kombinasjonen som resulterte i lavest RMSE på valideringssettet, ble valgt som den beste modellen. Denne modellen ble deretter lagret som den beste modell for videre bruk.

Feature importance

For å forbedre modellens ytelse og redusere kompleksiteten, ble det utført en analyse av variabelviktighet. Ved hjelp av feature importance fra den valgte modellen ble hver variabel vurdert basert på dens viktighet til modellens predikasjonsevne. Variablene ble deretter sortert etter viktighet, og ulike threshold for lav viktighet ble testet for å identifisere et optimalt sett av funksjoner.

Gjennom feature importance ble flere variabler med ulike viktighetsnivåer forsøkt fjernet for å se om modellen kunne forbedres ytterligere. Til tross for flere forsøk på å justere threshold, førte ikke fjerning av variabler med lav viktighet til noe reduksjon i RMSE. Dermed ble alle variabler beholdt i modellen, da hver bidro med viktige informasjon for predikasjonen. Denne prosessen bekreftet at modellens ytelse var best når alle opprinnelige variabler ble inkludert, noe som understreket at både mindre og mer betydningsfulle variabler samlet bidro til modellens nøyaktighet.

Etter denne analysen ble den kombinasjonen av modell og imputasjonsstrategi som ga lavest RMSE på valideringssettet, valgt som den beste modellen og lagret for videre bruk.


Generaliseringsevne

I denne modellen ble det observert at forskjellen på RMSE på testsettet og valideringssettet (23.6875 sammenlignet med 17.1718) var 6. Denne forskjellen kan være et resultat av flere faktorer og antyder at modellen har noen utfordringer med å generalisere fullt ut til ukjente data.

- Variasjon i datasettet: En mulig forklaring på forskjellen er at testsettet kan inneholde data som er mindre representert eller fraværende i treningssettene og valideringssettene. Testsettene kan for eksempel ha flere uteliggere som modellen ikke har sett tidligere, eller det kan inneholde tilfeller som treningssettet ikke dekker. Siden modellen aldri har blitt utsatt for slike unike tilfeller, kan dette føre til høyere feil når den predikerer på testsettet.

- Overfitting: En annen årsak kan være overfitting. Selv om modellen oppnådde lav RMSE på valideringssettet, kan dette tyde på at den har tilpasset seg spesifikke mønstre eller støy i trenings- og valideringsdata som ikke nødvendigvis er representativ for dataen i testsettet eller ny data. Overtilpassing kan ha oppstått fordi modellen lærer detaljer og unøyaktigheter fra treningsdataene, noe som kan gjøre at den presterer dårligere på testsettet. Overfitting skjer når modellen blir for godt tilpasset til treningsdata, og da vil modellen ofte miste deler av generalisering evnen.
- Tilfeldige variasjoner: En annen årsak som kan være er tilfeldige variasjoner i dataene mellom sett. Selv om trenings-, validerings-, og testsettene generelt er lik, kan små forskjeller i fordelingen av variabler, ekstremverdier eller spesifikke grupper likevel føre til variasjoner i ytelse. Slike forskjeller er naturlige og kan skape små avvik, selv i balanserte datasett.
- Visualisering:

Actual vs Predicted Values



Figur 14: Visualisering av prediksjon på valideringssett og testsett

Figuren viser prediksjonene på validerings- og testsettet, der den stiplede linjen representerer perfekt prediksjon. RMSE på valideringssettet er 17.1311 mens RMSE på testsettet er høyere 23.6862, noe som antyder at modellen har noen utfordringer med å generalisere til nye data.

Det er imidlertid positivt at modellen predikerer nøyaktig på korte oppholdslengder, noe som er viktig siden majoriteten av pasientoppholdene er korte. For noen praktiske formål kan det være mer verdifullt at modellen gir pålitelige prediksjoner på de kortere oppholdene, fremfor å ha litt bedre nøyaktighet på både korte og lange opphold. Modellen sliter mer med å predikere lengre opphold, noe som kan skyldes grunnene nevnt over.

Predikasjon

Den beste maskinlæringsmodellen ble brukt på sample data for å predikere oppholdslengden. Prediksjonene kan finnes i «predictions.csv»

Konklusjon

I denne oppgaven er det blitt bygget en maskinlæringsmodell for å predikere lengden på sykehusopphold ved å bruke et datsett med pasientopplysninger-, inkludert fysiologiske-, demografiske- og sykdomsalvorlighetsgraddata. Prosjektet startet med dataforberedelse, som inkluderte datarensing, behandling av manglende verdier, fjerning av uteliggere, og feature engineering for å skape mer informative variabler. Ved å bruke disse operasjonene reduserte jeg støy i dataene og lagde et bedre datagrunnlag som vil forbedrer modellens ytelse.

Jeg testet flere forskjellige modeller inkludert Random Forest, Lasso, MLPRegressor og Gradient Boosting, i kombinasjon med ulike imputasjonsmetoder for å håndtere manglende verdier. Den beste kombinasjonen av modell og imputasjon ble valgt basert på lavest RMSE på valideringssettet, og denne kombinasjonen ble deretter brukt til å evaluere ytelsen på testsettet. Den beste modellen viste seg å være en GradientBoostingRegressor med

parametrene `n_estimators=50` og `random_state=42`, kombinert med imputasjonsmetoden `knn_imputer` med 150 neighbours. Denne kombinasjonen ga lavest RMSE på valideringssettet og ble derfor valgt som den beste modellen for prediksjon av oppholdslengde.

Da jeg evaluerte modellens generaliseringsevne, kom det fram at modellen presterte bedre på valideringssettet enn på testsettet. Dette viser at det er potensial for videre forbedringer. Med mer tid kunne jeg ha gjennomført en grundigere utvelgelse av variabler, utforsket datasettet i større detalj, og gjort ytterligere feature engineering for å forbedre modellens ytelse. Det ville også vært fordelaktig å gjennomføre et grid search for å optimalisere hyperparametrene og dermed finjustere modellen ytterligere.

Til tross for forbedringspotensialet er jeg fornøyd med modellens evne til å oppnå god nøyaktighet på korte oppholdslengder, som utgjør majoriteten av dataene. I tillegg viser feature engineering-prosessen seg å ha vært vellykket, ettersom de nye variablene jeg lagde, som gjennomsnittlige overlevelsesestimer og helsetilstandskombinasjoner, har blitt blant de viktigste faktorene for å predikere oppholdslengde. Dette bekrefter at variabelutvelgelsen og -utviklingen bidro til å gjøre modellen mer informativ.

Referanseliste

(u.d.). Hentet fra Repository, UC Irvine Machine Learning:

<https://archive.ics.uci.edu/dataset/880/support2>

Blaser, N. (u.d.). *Innføring i data science*. Hentet fra <https://blasern.github.io/data-science-forelesningsnotater/intro.html>

